ViCivil-TKG: Bộ chuẩn đánh giá hệ thống hỏi–đáp pháp luật dân sự Việt Nam với kiểm định thời hiệu và chuỗi thẩm định đáp án vàng đa vòng

Nhóm nghiên cứu ViCivil-TKG

Kho dữ liệu và mã nguồn: `https://huggingface.co/datasets/datbazuka2502/vicivil-tkg` — `https://github.com/ntd25022006q/vicivil-tkg`

Tóm tắt. Chúng tôi giới thiệu **ViCivil-TKG**, bộ chuẩn đánh giá (benchmark) cho bài toán hỏi–đáp pháp luật dân sự Việt Nam, được xây dựng quanh hai thách thức ít được xử lý trong các bộ dữ liệu pháp lý hiện có: (i) *thời hiệu văn bản* — cùng một câu hỏi có đáp án khác nhau tại các mốc thời gian áp dụng khác nhau của đạo luật; và (ii) *độ tin cậy của đáp án vàng* — phần lớn câu hỏi sinh tự động có đáp án vàng chưa được kiểm chứng độc lập. Bộ chuẩn gồm **1.092 câu hỏi** đã công bố (281 câu lõi trong đó 12 câu viết tay và 269 câu sinh có kiểm soát; 106 câu mở rộng vòng 1; 64 câu mở rộng vòng 2 thuộc giai đoạn văn bản 1996–2015; 265 câu mở rộng vòng 3 và 376 câu vòng 4 mở rộng quy mô) trích từ kho 20 văn bản pháp luật với 13.151 đoạn văn bản, kèm 1.029 câu bị cách ly công khai vì không qua thẩm định. Toàn bộ đáp án vàng trải qua chuỗi thẩm định ba vòng: thẩm định hai tầng bằng hai mô hình giám sát, thẩm định lại hai vòng bằng LLM trọng số lớn hơn, và một lượt rà soát lần cuối (pass-3) bằng mô hình sâu hơn trên 99 câu nghi vấn cùng bài kiểm tra thỏa thuận độc lập trên 60 câu mẫu; sau chuỗi này *không còn câu hỏi nào ở trạng thái "không xác minh được"*. Trên bộ lõi, cơ chế lọc thời hiệu (TCR) cải thiện độ chính xác trích dẫn của mô hình sinh Qwen2.5-3B từ 0,488 lên 0,601 (McNemar $p = 5{,}8 \times 10^{-5}$), so với 0,004 của thiết lập không có ngữ cảnh; với cohort mở rộng giai đoạn 1996–2015, TCR nâng Hit@5 truy hồi từ 0,703 lên 0,781 và rerank đưa Hit@1 lên 0,703; trên hai cohort mở rộng quy mô (vòng 3/4, 641 câu), TCR nâng Hit@1 truy hồi 0,511→0,654 (vòng 4, $p = 6{,}3 \times 10^{-22}$) và cite_acc 0,527→0,657 (vòng 4, $p = 3{,}2 \times 10^{-10}$). Bộ dữ liệu, toàn bộ dấu vết thẩm định và kịch bản tái lập không cần GPU được công bố công khai.

Từ khoá: hỏi–đáp pháp lý; bộ dữ liệu tiếng Việt; truy hồi có thời hiệu; thẩm định đáp án vàng; RAG.

Abstract. We introduce **ViCivil-TKG**, a benchmark for Vietnamese civil-law question answering built around two under-addressed challenges: (i) *temporal validity* — the same question has different answers under different applicability windows of a statute; and (ii) *gold-label reliability* — most automatically generated questions carry unverified gold answers. The benchmark publishes **1,092 validated questions** (a 281-question core with 12 hand-written and 269 controlled-generated items; 106 round-1 extension items; 64 round-2 extension items from the 1996–2015 statute era; 265 round-3 and 376 round-4 scale-up items) over a corpus of 20 legal documents with 13,151 passages, together with **1,029 publicly quarantined questions** that failed adjudication. Every gold answer passes a four-stage adjudication chain: two-tier LLM auditing, two-round re-anchoring with a larger judge, a pass-3 sweep over 99 weak-gold suspects with guardrails, and an independent 60-question agreement audit; afterwards *no question remains unverifiable*. On the core set, temporal-consistency retrieval (TCR) raises the citation accuracy of Qwen2.5-3B from 0.488 to 0.601 (McNemar $p = 5.8 \times 10^{-5}$) against 0.004 without context; on the 1996–2015 extension cohort TCR lifts Hit@5 retrieval from 0.703 to 0.781 and reranking raises Hit@1 to 0.703; on the round-3/4 scale-up cohorts (641 questions) TCR raises Hit@1 from 0.511 to 0.654 (round 4, $p = 6.3 \times 10^{-22}$) and cite_acc from 0.527 to 0.657 (round 4, $p = 3.2 \times 10^{-10}$). Data, full adjudication trails, and a GPU-free reproduction script are released.

Keywords: legal question answering; Vietnamese datasets; temporal retrieval; gold-label adjudication; RAG.

1. Giới thiệu

Hệ thống hỏi–đáp pháp luật đòi hỏi mức độ chính xác cao hơn nhiều so với các miền mở: một câu trả lời sai điều luật áp dụng có thể dẫn tới hậu quả pháp lý thực tế. Xây dựng bộ đánh giá cho miền này gặp hai rào cản chính. Thứ nhất, văn bản pháp luật Việt Nam có *thời điểm hiệu lực* rõ ràng: Bộ luật Dân sự 2015 thay thế Bộ luật Dân sự 2005, nghị định hướng dẫn bị thay mới theo chu kỳ, do đó câu hỏi "thời hiệu khởi kiện yêu cầu đòi tài sản là bao lâu?" phải được trả lời bằng văn bản hợp lệ *tại mốc thời gian của câu hỏi*, không phải bằng văn bản mới nhất. Thứ hai, các bộ dữ liệu QA sinh tự động bằng LLM phần lớn mặc định đáp án vàng (gold) là đúng, trong khi thực tế việc neo vàng (gold anchoring) — chỉ ra đúng đoạn văn bản là cơ sở pháp lý — là chính nguồn lỗi lớn nhất.

Bài báo này trình bày ViCivil-TKG, bộ chuẩn được thiết kế để đo cả hai khía cạnh trên. Đóng góp của chúng tôi gồm: (C1) bộ chuẩn 1.092 câu hỏi công bố trên kho 20 văn bản pháp luật dân sự Việt Nam (13.151 đoạn), mỗi câu gắn mốc thời gian `as_of` và đáp án vàng neo tới định danh đoạn văn bản chính xác, cùng 1.029 câu cách ly công khai; (C2) *chuỗi thẩm định vàng đa vòng* — một quy trình ba giai đoạn với nhiều mô hình giám sát độc lập, guardrail khi áp dụng, dấu vết provenance đầy đủ và cơ chế cách ly công khai các câu không đạt; (C3) giao thức đánh giá truy hồi có kiểm định thời hiệu (TCR) cùng phép thử thống kê cặp cho cả truy hồi lẫn sinh; (C4) phân tích lỗi theo tầng chất lượng vàng và kịch bản tái lập hoàn toàn không cần GPU.

Bài báo được tổ chức như sau: Mục 2 tóm tắt công trình liên quan; Mục 3 mô tả kho văn bản và quy trình sinh – thẩm định dữ liệu; Mục 4 trình bày thiết lập thực nghiệm; Mục 5 báo cáo kết quả; Mục 6 thảo luận hạn chế; Mục 7 kết luận.

2. Công trình liên quan

Bộ chuẩn truy hồi và QA. BEIR [4] chuẩn hoá đánh giá zero-shot cho truy hồi trên nhiều miền; LexGLUE [5] gom các tác vụ NLP pháp lý tiếng Anh. Các bộ này không có phân đoạn thời hiệu, không có văn bản tiếng Việt, và đáp án vàng được kiểm chứng bởi con người với chi phí cao — khác với hướng đi sinh có kiểm soát kèm thẩm định đa vòng của chúng tôi. SQuAD 2.0 [6] đưa câu hỏi "không có đáp án" vào đánh giá, gần với cơ chế từ chối trả lời (abstain) mà chúng tôi đo thông qua tỷ lệ trả lời "Không đủ thông tin".

Truy hồi dày đặc và hợp nhất. BM25 [1] vẫn là cơ sở truy hồi từ kho mạnh; DPR [3] và các mô hình embedding dày đặc bổ sung tín hiệu ngữ nghĩa; Reciprocal Rank Fusion [2] hợp nhất hai danh sách xếp hạng mà không cần huấn luyện lại. Chúng tôi dùng đúng tổ hợp BM25 + dense + RRF cho mọi thí nghiệm, và thêm lớp lọc thời hiệu (TCR) dựa trên đồ thị thời gian của văn bản. BGE-reranker [8] được dùng làm bước xếp hạng lại; RAG [7] và dòng mô hình Qwen [9] là nền cho điều kiện sinh có trích dẫn.

3. Bộ dữ liệu ViCivil-TKG

3.1. Kho văn bản pháp luật

Kho văn bản gồm 20 văn bản pháp luật dân sự Việt Nam giai đoạn 1995–2026 (Bộ luật Dân sự 1995/2005/2015, Bộ luật Tố tụng dân sự 2004 và VBHN, Luật Hôn nhân và gia đình 2000/2014, Luật Thi hành án dân sự 2008 và VBHN, Luật Nuôi con nuôi 2010, Luật Trách nhiệm bồi thường của Nhà nước, nghị định hướng dẫn, văn bản hợp nhất, cùng các văn bản 2026 mới ban hành), được phân đoạn thành **13.151 đoạn** theo cấu trúc điều – khoản – điểm. Mỗi đoạn mang các trường provenance bắt buộc: `source_url`, `source_type` (official / official-copy / semi-official / mirror), `fetched`, và cửa sổ hiệu lực `valid_from`/`valid_to` lấy từ đồ thị thời gian gồm 37 văn bản với 24 cạnh nối tiếp – sửa đổi. Hai đoạn trích từ tệp `.doc` chuyển đổi hỏng (nội dung nhiễu nhị phân, không được tham chiếu bởi bất kỳ câu hỏi nào) đã bị loại và ghi vào nhật ký loại bỏ.

3.2. Sinh câu hỏi có kiểm soát

Câu hỏi được sinh bằng mô hình `qwen2.5:14b` chạy cục bộ, theo lô từ đoạn nguồn với ba ràng buộc: (i) mỗi câu gắn `as_of` nằm trong cửa sổ hiệu lực của văn bản nguồn (chọn điểm giữa pha hữu dụng của văn bản); (ii) câu hỏi phải được trả lời được *chỉ từ* đoạn nguồn và các điều liên hệ trực tiếp; (iii) dedup bên trong lô bằng vector câu hỏi (embedding 768 chiều, `embeddinggemma:300m`). Câu lõi gồm 269 câu sinh trên 14 văn bản có hiệu lực gần đây cộng 12 câu viết tay (CIV001–CIV012) dùng làm bài kiểm tra đặc biệt (trong đó một câu kiểm tra khả năng từ chối khi văn bản chưa hiệu lực). Hai đợt mở rộng bổ sung 106 câu công bố (vòng 1, từ 242 câu sinh) và 154 câu sinh từ ba văn bản giai đoạn 1996–2015 (Bộ luật Tố tụng dân sự 2004, Nghị định 158/2005 về hộ tịch, Nghị định 126/2014 hướng dẫn Luật HNGD) với quota theo văn bản là 103/30/27. Đợt mở rộng quy mô (vòng 3) lấy mẫu 620 đoạn theo quota từng văn bản (tối đa 150/văn bản), sinh 590 câu hợp lệ, loại 9 câu gần trùng lặp (Jaccard $\geq$ 0,60 với mọi câu trước đó) và công bố 265 câu sau cùng chuỗi thẩm định hai tầng và neo lại; 316 câu bị cách ly. Bài audit phát hành phát hiện 28 va chạm định danh câu hỏi do sinh song song (hai câu khác nhau dùng chung một ID khiến verdict lưu không tin cậy); mọi cặp bị ảnh hưởng được thẩm định lại từ đầu với ID duy nhất và nhật ký sửa được công bố.

3.3. Chuỗi thẩm định đáp án vàng

Đây là đóng góp trung tâm của bộ dữ liệu. Chuỗi gồm các tầng sau, toàn bộ dấu vết lưu trong `benchmark/`:

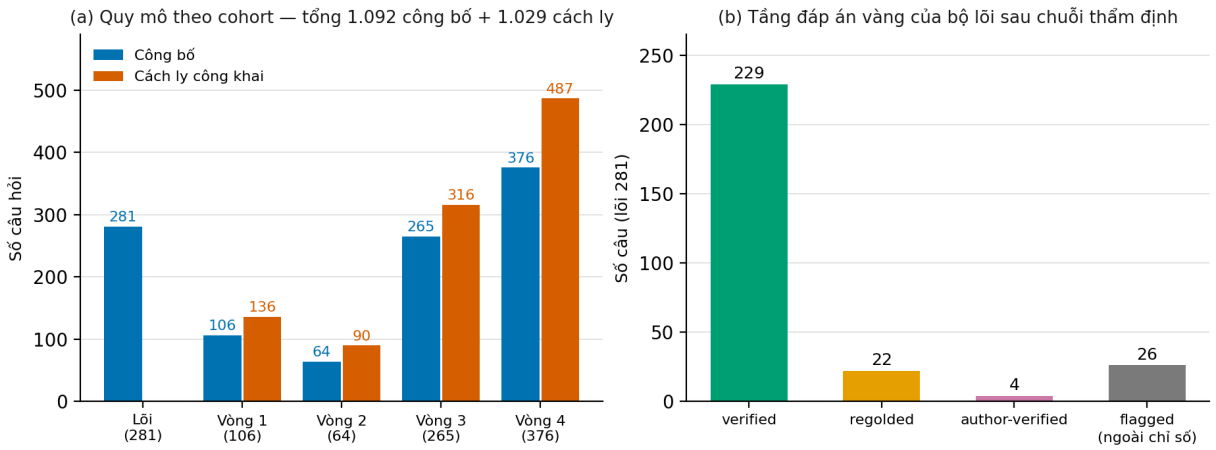
1. **Thẩm định hai tầng khi sinh.** Mỗi câu sinh được chấm ngay bởi mô hình 8B (`usable: yes/partial/no`); mọi câu không đạt "yes" được chấm lại bởi mô hình sâu hơn 14B kèm yêu cầu trích bằng chứng. Câu nào không qua cả hai tầng bị cách ly.

2. **Neo lại hai vòng.** Với các câu vàng nghi vấn, quy trình neo lại (regold) đề xuất đoạn thay thế rồi yêu cầu LLM giám sát xác nhận *hai vòng độc lập*; chỉ đoạn được cả hai vòng chấp nhận mới được đổi. Trên bộ lõi, 38 câu được neo lại theo cách này.

3. **Pass-3: rà soát cuối trên 99 câu nghi vấn.** Toàn bộ nhóm vàng yếu nghi vấn (các câu chưa từng xác minh được, các câu đã regold, nhóm câu nhiều phần, nhóm viết tay) được một thẩm định viên sâu hơn (`qwen3:14b`) chấm lại theo giao thức "gold hiện tại + 5 ứng viên truy hồi": kết luận *gold-ok* (66 câu), *reanchor* (4), hay *flag* (29; trong đó 3 đề xuất neo lại được áp dụng và 1 bị guardrail chặn vì không nằm trong danh sách ứng viên). Việc áp dụng đi kèm guardrail nghiêm ngặt: đoạn thay thế phải tồn tại trong kho, phải nằm trong danh sách ứng viên đã lưu, và phải hợp lệ theo cửa sổ thời hiệu tại `as_of`.

4. **Kiểm tra thỏa thuận độc lập.** Trên mẫu ngẫu nhiên cố định 60 câu (seed 20261101), thẩm định viên độc lập chọn cơ sở pháp lý trong 8 ứng viên: 56/60 câu có kết quả phân tích được, trong đó 31/56 chọn đúng tập vàng (**0,554**) và 32/56 trùng khớp đoạn chính xác (**0,571**). Chúng tôi công bố con số này *không lọc* như một thước đo độ khó gắn vàng của miền, đồng thời nhấn mạnh đây là kiểm tra giữa hai mô hình, không thay thế đánh giá giữa người (Mục 6).

Sau chuỗi trên, **281/281 câu lõi có đáp án vàng đã xác minh** (trước pass-3 còn 2 câu ở trạng thái "không xác minh được"; cả hai được thẩm định viên pass-3 neo lại thành công tới đoạn cụ thể). Trong 4 câu viết tay bị pass-3 cờ, chúng tôi *giữ nguyên tầng "author-verified"* theo nguyên tắc thẩm định của người có quyền ưu tiên hơn mô hình, và ghi dissent của mô hình vào trường `weak_review`. Sau khi áp dụng pass-3, tổng cộng **26** câu lõi mang cờ `flagged` (bị loại khỏi mọi chỉ số chính, công khai kèm lý do), **22** câu ở tầng `regolded`, 229 câu `verified`, 4 câu `author-verified`.



Hình 1: Cấu trúc ViCivil-TKG: ba cohort công bố theo tầng chất lượng vàng và phần cách ly công khai. Các câu cách ly không bao giờ được tính vào chỉ số.

3.4. Chống trùng lặp giữa các cohort

Vòng 2 bổ sung bước còn thiếu ở vòng 1: so độ tương tự cosine giữa mọi câu mới sinh với toàn bộ 387 câu đã công bố (ngưỡng 0,95). Một câu bị phát hiện trùng lặp gần như tuyệt đối với câu lõi đã có (cosine 0,9931) và bị cách ly; 0 câu trùng với nhóm cách ly của vòng 1. Toàn bộ kết quả đối chiếu lưu trong `extension2_dedup_audit.json`.

3.5. Cấu trúc công bố

Hình 1 tóm tắt cấu trúc bộ dữ liệu. Bộ chuẩn công bố **1.092 câu** trên năm cohort (281 lõi, 106 vòng 1, 64 vòng 2, 265 vòng 3, 376 vòng 4) và **1.029 câu cách ly** (136 vòng 1, 90 vòng 2, 316 vòng 3, 487 vòng 4) kèm đầy đủ dấu vết thẩm định cho từng câu. Bộ lõi được tách stratified thành dev/test 140/141. Mọi cohort mở rộng đều công bố stratified metrics riêng theo tầng vàng; các câu cách ly *không bao giờ* vào chỉ số.

4. Thiết lập thực nghiệm

Truy hồi. Giao thức hợp nhất: BM25 (Python thuần, k_1=1,2, b=0,75) + dense 768 chiều (vector đoạn đã lưu, `embeddinggemma:300m`) hợp nhất bằng RRF k=60, lấy 200 ứng viên mỗi nhánh. Chấm điểm đối chiếu định danh đoạn vàng chính xác; báo cáo Hit@{1,3,5,10} và MRR. TCR (temporal-consistency retrieval) lọc ứng viên theo cửa sổ hiệu lực của văn bản tại `as_of` của câu hỏi; văn bản ngoài đồ thị được giữ nguyên. Với cohort mở rộng, thêm điều kiện xếp hạng lại BGE-reranker-v2-m3 trên 30 ứng viên rồi áp TCR. Ý nghĩa thống kê: Wilcoxon cặp trên nghịch đảo hạng của lần trúng vàng đầu tiên.

Sinh có trích dẫn. Qwen2.5-3B-Instruct (greedy, tối đa 180 token mới, batch 6) chạy trên bốn điều kiện: *norag* (không ngữ cảnh), *rag_hybrid* (top-5 truy hồi hợp nhất), *rag_hybrid_tcr* (top-5 sau TCR), *rag_rerank_tcr* (top-5 sau rerank + TCR). Đo *cite_acc* (câu trả lời có nêu đúng điều luật trong tập vàng), *span_F1* (F1 token với văn bản vàng), *abstain* (tỷ lệ trả lời "Không đủ thông tin"), *ctx_hit5* (tập vàng xuất hiện trong ngữ cảnh). Ý nghĩa thống kê: McNemar chính xác cho cite_acc, Wilcoxon cho span_F1.

Tái lập. Toàn bộ chỉ số truy hồi và chấm lại LLM đều tính từ các artefact đã lưu (vector, xếp hạng, câu trả lời), chạy được bằng `tools/reproduce.sh` mà không cần GPU hay truy cập mạng.

Bảng 1: Suite baseline trên bộ lõi 281 câu, một harness thống nhất (BM25 k_1=1,2, b=0,75; dense 768 chiều; RRF k=60; TCR = lọc cửa sổ hiệu lực). MRR tính trong cửa sổ ứng viên.

Hệ thống	Hit@1	Hit@5	Hit@10	MRR
BM25 thuần	0,331	0,644	0,740	0,472
Dense thuần	0,356	0,666	0,772	0,495
Hybrid (RRF)	0,399	0,733	0,811	0,546
Hybrid + TCR	**0,537**	**0,811**	**0,879**	**0,660**

Wilcoxon cặp: TCR so với hybrid $p = 8{,}5 \times 10^{-23}$; hybrid so với dense $p = 1{,}8 \times 10^{-4}$; hybrid so với BM25 $p = 7{,}9 \times 10^{-8}$; dense so với BM25 $p = 0{,}257$ (không có ý nghĩa thống kê).

Bảng 2: Truy hồi trên bộ lõi 281 câu (hybrid BM25+dense+RRF, lọc thời hiệu TCR).

Nhóm	n	Hit@1	Hit@3	Hit@5	Hit@10
Toàn bộ	281	0,541	0,740	0,811	0,879
verified	229	0,585	0,760	0,821	0,895
regolded	22	0,273	0,773	0,864	0,909
author-verified	4	0,250	0,500	0,750	0,750
flagged (không tính điểm chính)	26	0,423	0,577	0,692	0,731

5. Kết quả

5.1. Truy hồi trên bộ lõi

Bảng 2 báo cáo kết quả trên 281 câu lõi với giao thức hybrid+TCR đã tài liệu hoá. Điểm tổng thể đạt Hit@5 0,811 và MRR 0,662 (chấm lại toàn danh sách sau khi persist pass-3; bảng suite so sánh 4 hệ thống dùng cửa sổ ứng viên top-200 nên MRR là 0,660 — cả hai snapshot đều được công bố, không thay thế im lặng); trên tầng vàng `verified` (229 câu) đạt Hit@5 0,821 và MRR 0,693. Ba tầng vàng thấp hơn — `flagged` (26 câu, Hit@5 0,692), `regolded` (22 câu, Hit@1 chỉ 0,273 nhưng Hit@5 0,864), `author-verified` (4 câu) — được công bố nguyên vẹn: pattern "Hit@1 thấp, Hit@5 cao" của tầng regolded cho thấy các đoạn được neo lại thường nằm sâu trong danh sách ứng viên, đúng loại trường hợp mà không có thẩm định đa vòng sẽ bị tính là trượt.

5.2. Hiệu ứng của chuỗi thẩm định vàng

Bảng 3 so sánh xếp hạng lưu trước và sau thẩm định trên hai danh sách ứng viên. Neo lại vàng hai vòng cộng pass-3 nâng Hit@1 từ 0,448 lên 0,484 và MRR từ 0,596 lên 0,621 trên danh sách rerank; hiệu ứng tương tự trên danh sách hybrid. Đây là lượng cải thiện "miễn phí" thu được *không phải từ mô hình truy hồi* mà từ chất lượng vàng — bổ sung bằng chứng cho luận điểm rằng thẩm định vàng là đầu tư có lợi nhất trong xây dựng bộ chuẩn pháp lý.

5.3. Sinh có trích dẫn trên bộ lõi

Bảng 4 và Hình 2 trình bày bốn điều kiện. Không có ngữ cảnh, mô hình gần như không bao giờ nêu đúng điều luật (cite_acc 0,004) và từ chối trả lời 54,8% số câu. Cung cấp ngữ cảnh hợp nhất đưa cite_acc lên 0,488; lọc thời hiệu đẩy lên **0,601** (+0,114 điểm tuyệt đối, McNemar $p = 5{,}8 \times 10^{-5}$; mọi cặp so sánh với no-RAG đạt $p < 10^{-40}$). Rerank+TCR giữ mức cite_acc tương đương (0,604, $p = 0{,}001$ so với hybrid) nhưng tăng ctx_hit5 lên 0,850 và span_F1 lên 0,490. Tỷ lệ từ chối giữ ổn định quanh 11% khi có ngữ cảnh — mô hình hiếm khi "nói bừa" khi trích dẫn không đủ, hợp lý với thiết kế prompt.

Bảng 3: Hiệu ứng thẩm định vàng trên bộ lõi: chấm cùng danh sách ứng viên với vàng cũ và vàng sau thẩm định (281 câu).

	Danh sách rerank			Danh sách hybrid		
Tập vàng	Hit@1	Hit@5	MRR	Hit@1	Hit@5	MRR
Trước thẩm định	0,448	0,794	0,596	0,406	0,737	0,548
Sau thẩm định (281/281 xác minh)	**0,484**	**0,808**	**0,621**	**0,441**	**0,744**	**0,571**

Bảng 4: Sinh có trích dẫn trên bộ lõi (Qwen2.5-3B-Instruct, greedy, 180 token).

Điều kiện	cite_acc	span_F1	abstain	ctx_hit5	n
No-RAG	0,004	0,324	0,548	—	281
RAG hybrid	0,488	0,465	0,110	0,740	281
RAG hybrid + TCR	**0,601**	0,489	0,107	0,815	281
RAG rerank + TCR	0,600	**0,490**	0,111	**0,850**	280

5.4. Cohort mở rộng: vòng 1–3

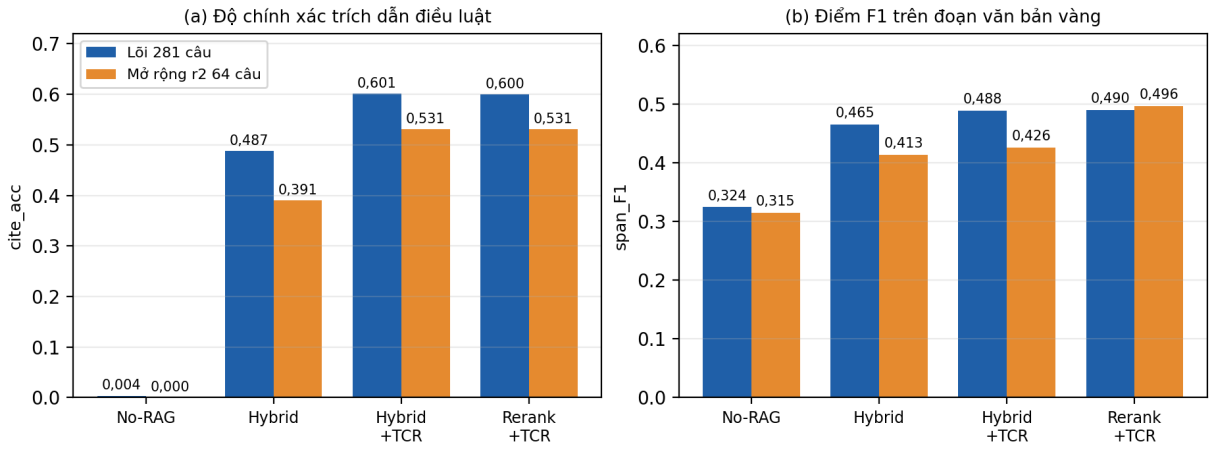
Bảng 5 tổng hợp ba cohort mở rộng. Trên vòng 1 (106 câu), TCR nâng Hit@5 từ 0,906 lên 0,925 (Wilcoxon $p = 2{,}1 \times 10^{-5}$). Trên vòng 2 — văn bản 1996–2015 hiếm và lỗi thời hơn — mọi chỉ số thấp hơn rõ rệt: TCR nâng Hit@5 từ 0,703 lên 0,781 và MRR từ 0,517 lên 0,648 ($p = 4{,}0 \times 10^{-5}$); rerank+TCR đạt Hit@1 **0,703** ($p = 1{,}4 \times 10^{-3}$ so với TCR). Vòng 3 (265 câu trên 19 văn bản, cohort mở rộng quy mô) ở mức trung gian: TCR nâng Hit@1 0,494→0,615 và Hit@5 0,819→0,857 ($p = 5{,}7 \times 10^{-17}$); rerank+TCR đạt Hit@1 **0,668** và Hit@5 **0,909** ($p = 5{,}2 \times 10^{-3}$ so với TCR — cohort đầu tiên mà rerank cộng thêm mức tăng có ý nghĩa trên TCR). Về sinh, chuỗi cải thiện tương tự xuất hiện trên vòng 2 (0,000 → 0,531 cite_acc), dù span_F1 của rerank+TCR tốt hơn TCR thuần mà không qua ngưỡng ý nghĩa (Wilcoxon $p = 0{,}083$) — chúng tôi báo cáo nguyên trạng, không khẳng định quá mức; sinh có trích dẫn cho vòng 3 chưa chạy và để trống, không nội suy. Tầng `regolded` của vòng 2 (11 câu) yếu nhất toàn bộ bộ chuẩn (Hit@1 0,091) và được ghi nhãn công khai; đây là hệ quả trực tiếp của việc neo vàng trên văn bản cũ.

5.5. Thống kê tổng hợp

Mọi so sánh chính đều kèm phép thử cặp: (i) truy hồi, TCR so với base: $p = 2{,}1 \times 10^{-5}$ (vòng 1), $p = 4{,}0 \times 10^{-5}$ (vòng 2); (ii) rerank+TCR so với TCR: $p = 1{,}4 \times 10^{-3}$ (vòng 2); (iii) sinh, hybrid+TCR so với hybrid: McNemar $p = 5{,}8 \times 10^{-5}$ (lõi), $p = 0{,}012$ (vòng 2); no-RAG so với hybrid+TCR: $p < 10^{-40}$ trên cả hai cohort. Các so sánh span_F1 khi không đạt ngưỡng được ghi rõ là không có ý nghĩa.

6. Thảo luận và hạn chế

Hạn chế của dữ liệu. (1) Miền hẹp: toàn bộ câu hỏi thuộc luật dân sự – tố tụng dân sự; 20 văn bản và 1.092 câu vẫn nhỏ so với các benchmark đa miền. (2) Tầng vàng không đồng nhất: 26 câu lõi bị cờ và được loại khỏi chỉ số chính; tầng regolded (22 câu) có Hit@1 thấp một cách có hệ thống — người dùng bộ chuẩn cần stratify theo tầng như chúng tôi đã làm. (3) Thỏa thuận giữa thẩm định viên độc lập chỉ đạt 0,554 trên mẫu 60 câu; đây là kiểm tra giữa các mô hình trên tác vụ chọn đoạn trong 8 ứng viên — nhiệm vụ vốn nhiều ứng viên đúng — và *không thay thế được* đánh giá con người. Kit thẩm định người đã sẵn sàng sử dụng ngay: bảng 60 câu phân tầng, ba packet độc lập cho ba thẩm định viên (xáo trộn với seed cố định riêng; mỗi packet chỉ hiển thị cột chấm của người đó để bảo đảm tính độc lập), rubric DUNG/SAI/MỘT PHẦN kèm hướng dẫn, và fixture kiểm thử có nhãn rõ *TEST-ONLY* trên đó triển khai Cohen/Fleiss κ tái lập chính xác giá trị tham chiếu tính tay; chỉ còn bước chạy với thẩm định viên người



Hình 2: cite_acc (a) và span_F1 (b) theo bốn điều kiện trên bộ lõi 281 câu và cohort mở rộng vòng 2 (64 câu). Lọc thời hiệu và rerank cải thiện nhất quán trên cả hai cohort, dù cohort 1996–2015 khó hơn rõ rệt.

Bảng 5: Cohort mở rộng: truy hồi (base so với TCR) và sinh có trích dẫn. MRR ghi trong ngoặc.

	Vòng 1 (n=106)		Vòng 2 1996–2015 (n=64)		Vòng 3 (n=265)	
Điều kiện	Hit@1	Hit@5	Hit@1	Hit@5	Hit@1	Hit@5
Hybrid (base)	0,547 (0,700)	0,906	0,359 (0,517)	0,703	0,494 (0,629)	0,819
Hybrid + TCR	**0,689** (0,790)	**0,925**	0,531 (0,648)	0,781	0,615 (0,724)	0,857
Rerank + TCR	—	—	**0,703** (0,766)	**0,828**	**0,668** (0,775)	**0,909**
	cite_acc	span_F1	cite_acc	span_F1	cite_acc	span_F1
No-RAG	—		0,000	0,315	—	
RAG hybrid	—		0,391	0,413	—	
RAG hybrid + TCR	—		0,531	0,426	—	
RAG rerank + TCR	—		0,531	**0,497**	—	

thật trước khi công bố κ. (4) Câu hỏi sinh từ LLM, do đó mang thiên lệch của mô hình sinh; chúng tôi giảm nhẹ bằng dedup vector, audit hai tầng và cách ly công khai, nhưng không loại trừ hoàn toàn.

Hạn chế của đánh giá. Các thí nghiệm dùng một mô hình sinh 3B và một reranker; chưa có baseline LLM lớn hơn hay fine-tune trên miền. TCR dựa trên đồ thị thời gian thủ công xác nhận; sai sót trong cửa sổ hiệu lực sẽ truyền trực tiếp vào lọc. Chỉ số cite_acc đo việc nêu đúng *số* điều luật, chưa đo việc trích đúng *đoạn*.

7. Kết luận

ViCivil-TKG cho thấy hai nguyên tắc — kiểm định thời hiệu và thẩm định vàng đa vòng với cách ly công khai — có thể được vận hành nhất quán trên dữ liệu pháp lý tiếng Việt, và cả hai đều cho hiệu quả đo được: TCR cải thiện cite_acc +0,114 điểm ($p < 10^{-4}$) và chuỗi thẩm định nâng chất lượng neo vàng trên mọi tầng. Bộ chuẩn 1.092 câu kèm 1.029 câu cách ly, dấu vết provenance đầy đủ và kịch bản tái lập không GPU được công bố để cộng đồng kiểm chứng và mở rộng; hướng tiếp theo ưu tiên là thẩm định con người trên mẫu phân tầng, mở rộng sang văn bản cấp thông tư và các miền luật lân cận, và benchmark các mô hình sinh lớn hơn.

Tài liệu

[1] S. Robertson, H. Zaragoza, “The Probabilistic Relevance Framework: BM25 and Beyond,” *Foundations and Trends in Information Retrieval*, 3(4), 2009.

[2] G. V. Cormack, C. L. A. Clarke, S. Büttcher, “Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods,” *SIGIR*, 2009.

[3] V. Karpukhin *et al.*, “Dense Passage Retrieval for Open-Domain Question Answering,” *EMNLP*, 2020.

[4] N. Thakur *et al.*, “BEIR: A Heterogeneous Benchmark for Zero-shot Evaluation of Information Retrieval Models,” *NeurIPS Datasets and Benchmarks*, 2021.

[5] I. Chalkidis *et al.*, “LexGLUE: A Benchmark Dataset for Legal Language Understanding in English,” *ACL*, 2022.

[6] P. Rajpurkar, R. Jia, P. Liang, “Know What You Don’t Know: Unanswerable Questions for SQuAD,” *ACL*, 2018.

[7] P. Lewis *et al.*, “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks,” *NeurIPS*, 2020.

[8] S. Xiao *et al.*, “C-Pack: Packaged Resources To Advance General Chinese Embedding,” *SIGIR*, 2024.

[9] A. Yang *et al.*, “Qwen2.5 Technical Report,” *arXiv:2412.15115*, 2024.